Practica 2

November 10, 2018

PARTE 1: Regresión logística

1. Bibliotecas necesarias para la práctica

```
In [8]: #bibliotecas
        import numpy as np
        import matplotlib.pyplot as plt
        import math
        import scipy.optimize as opt
```

2. Extraemos los datos del csv. X contiene las dos primeras columnas e Y contiene la última columna

```
In [9]: from pandas.io.parsers import read_csv
        valores = read_csv('C:/Users/carli_000/Desktop/ex2data1.csv', header= None)
        X = valores.iloc[:,:-1]
        Y = valores.iloc[:,2]

        #print(X, Y)
```

3. Visualización de los datos:

X es la nota del primer examen e Y es la nota del segundo examen. Dibujamos + para las notas que son positivas. Dibujamos puntos amarillos para las notas que son negativas.

```
In [137]: def graficaEjemplo1():
          #Obtiene un vector con los índices de los ejemplos positivos
              positivos = Y == 1
              negativos = Y == 0
          # Dibuja los ejemplos positivos
              plt.scatter(X[positivos][0], X[positivos][1], marker='+' , c='k')
              plt.scatter(X[negativos][0], X[negativos][1],marker ='o', c='yellow')
              plt.legend(('admitidos', 'no admitidos'))
              plt.xlabel('Nota 1 examen')
              plt.ylabel('Nota 2 examen')


          graficaEjemplo1()
```

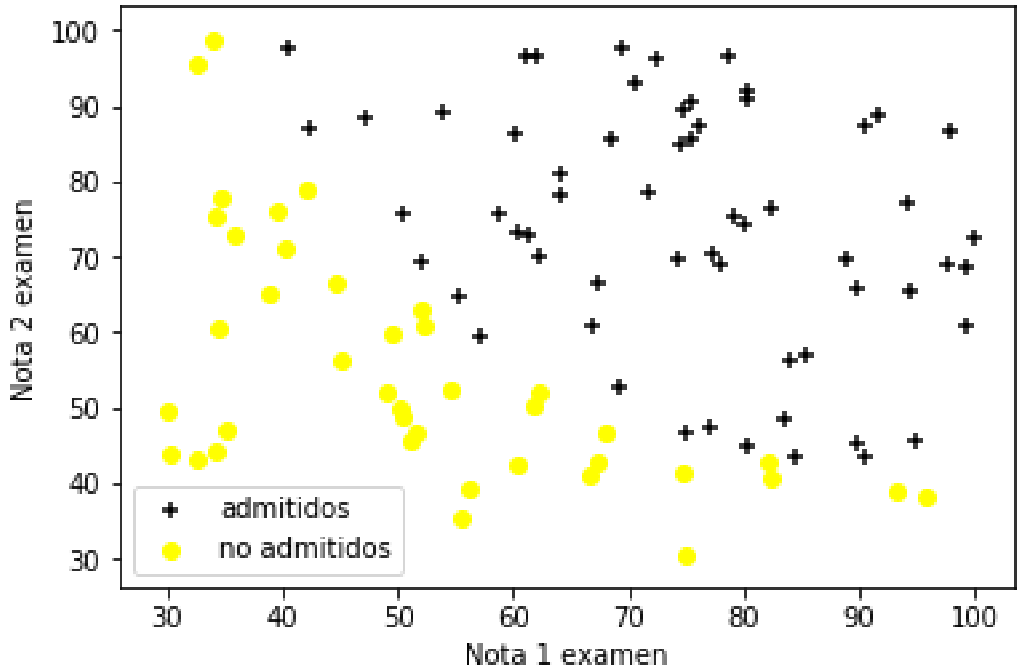

4. Función sigmoide

```
In [138]: #Funcion sigmoide
          def h(z):
              return 1/(1 + np.exp(-z))
```

Añadimos una columna de 1's a X

```
In [139]: [m,n]=X.shape
          ones = np.ones((m,1))
          X_aux = np.hstack((ones, X))
```

5. Cálculo de la función de coste

Para comprobar que para theta inicializada a 0 da el valor correcto. Realizamos la función de coste vectorizada según la formula.

```
In [140]: #funcion de coste vectorizada

          def funCoste(theta , X, Y):
              coste = (-1) * (np.matmul(np.transpose(np.log(h(X@theta))), Y) +
                              np.matmul(np.transpose(np.log(1 - h(X@theta))), (1-Y)))/m

              return coste
          funCoste(np.zeros((3,1)), X_aux, Y)
```

Out[140]: array([0.69314718])

```
In [141]: Y_aux = Y[:, np.newaxis]
```

6. Realización del gradiente vectorizado.

```
In [142]: #gradiente vectorizado

          def gradiente(theta, X, Y):
             # print(np.subtract(h(X@theta),Y))
              return ((1/m) * np.transpose(X) @ (h(X @ theta) - Y))
          gradiente(np.zeros((3,1)), X_aux, Y_aux)
```

```
Out[142]: array([[ -0.1       ],
                 [-12.00921659],
                 [-11.26284221]])
```

7. Cálculo del valor óptimo de los parámetros

```
In [143]: #Calculo del valor optimo de los parámetros
          result = opt.fmin_tnc(func= funCoste, x0=np.zeros((3,1)).flatten(), fprime=gradiente
          theta_opt = result[0]
          #funcion de coste con theta optimizado
          costeThetaOp = funCoste(theta_opt, X_aux, Y_aux)
          print(costeThetaOp)
```

```
[0.2034977]
```

8. Pintamos la frontera de decision con los valores de theta optimizados

```
In [144]: graficaEjemplo1()
          valores_x = [np.min(X_aux [:, 1] -2), np.max(X_aux[:, 2] +2)]
          valores_y = -1 / theta_opt[-1] * (theta_opt[0] + np.dot(theta_opt[1], valores_x))
          linea_decision = plt.plot(valores_x, valores_y)

          plt.show()
```

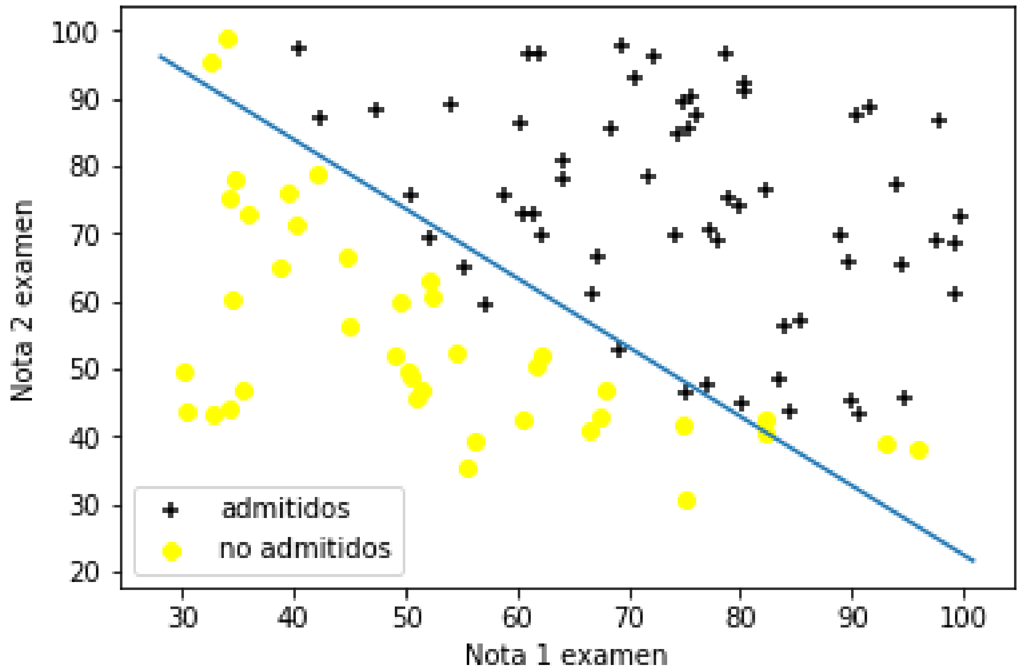

9.Calculo del porcentaje ejemplos de entrenamiento que se clasifican correctamente utilizando los valores de theta

```
In [145]: #Evaluacion de la regresion logistica
          def porcentaje(X_aux, Y_aux,theta):
              correcto = 0
              for i in range(0,m):
                  s = h(np.dot(X_aux[i],theta))
                  if(s>=0.5):
                      s=1
                  else:
                      s=0
                  if(Y_aux[i] == s):
                      correcto = correcto + 1
              porcentaje = (correcto/m) * 100
              return porcentaje
          p = porcentaje(X_aux, Y_aux, theta_opt)
          print(p)
```

```
89.0
```

PARTE 2: Regresión logística regularizada

1. Importamos las bibliotecas necesarias

```
In [140]: from pandas.io.parsers import read_csv
          valores = read_csv('C:/Users/carli_000/Desktop/ex2data2.csv', header= None)
          X2 = valores.iloc[:,:-1]
          Y2 = valores.iloc[:,2]
```

2. Representamos la gráfica en el que el eje x es el resultado del test del microchip 1 y el eje y es el resultado del test del microchip 2 en función de y (si el funciona o no el microchip)

```
In [141]: def graficaEjemplo2():
          #Obtiene un vector con los índices de los ejemplos positivos
              positivos = Y2 == 1
              negativos = Y2 == 0
          # Dibuja los ejemplos positivos
              plt.scatter(X2[positivos][0], X2[positivos][1], marker='+' , c='k')
              plt.scatter(X2[negativos][0], X2[negativos][1], marker ='o', c='yellow')
              plt.legend(('y = 1', 'y = 0'))
              plt.xlabel('microchip test 1')
              plt.ylabel('microchip test 2')


          graficaEjemplo2()
```

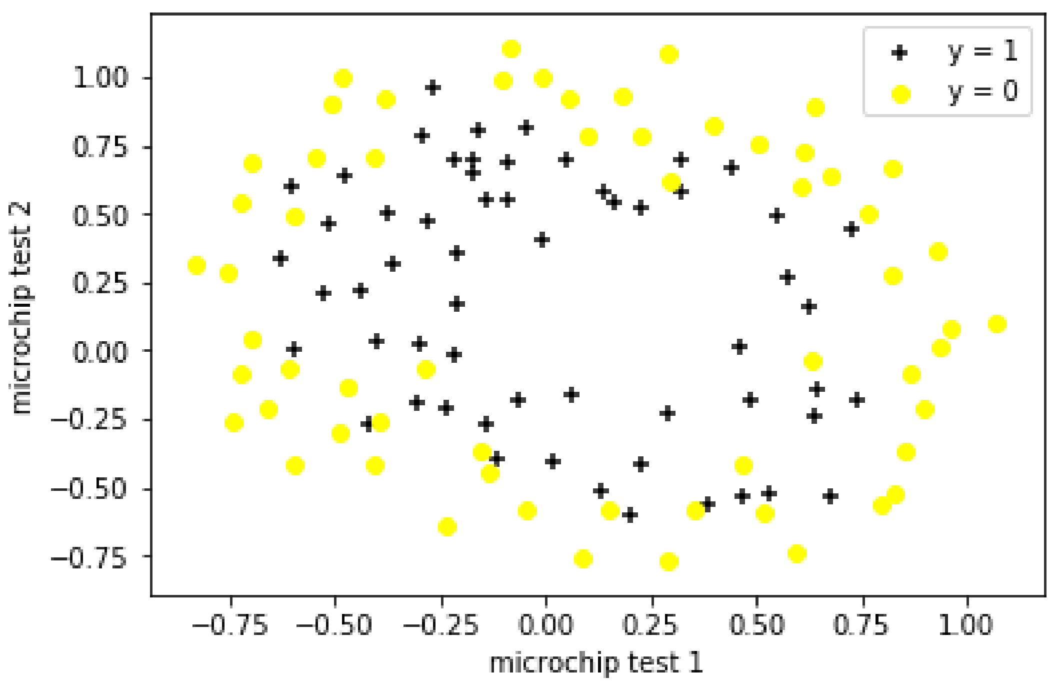

3. Importamos las bibliotecas necesarias

```
In [142]: import sklearn.preprocessing as Pol
```

4. Mapeo de los atributos: utilizamos polynomialFeatures para extender cada ejemplo de entrenamiento con los términos polinómicos de x1 y x2 hasta la sexta potencia, completando así un total de 28 atributos para cada ejemplo.

```
In [143]: #def mapFeature:
          def mapFeature():
              poly = Pol.PolynomialFeatures(6)
              return poly.fit_transform(X2)
          mapFeature()
```

```
Out[143]: array([[ 1.00000000e+00,  5.12670000e-02,  6.99560000e-01, ...,
                   6.29470940e-04,  8.58939846e-03,  1.17205992e-01],
                 [ 1.00000000e+00, -9.27420000e-02,  6.84940000e-01, ...,
                   1.89305413e-03, -1.39810280e-02,  1.03255971e-01],
                 [ 1.00000000e+00, -2.13710000e-01,  6.92250000e-01, ...,
                   1.04882142e-02, -3.39734512e-02,  1.10046893e-01],
                 ...,
                 [ 1.00000000e+00, -4.84450000e-01,  9.99270000e-01, ...,
                   2.34007252e-01, -4.82684337e-01,  9.95627986e-01],
                 [ 1.00000000e+00, -6.33640000e-03,  9.99270000e-01, ...,
                   4.00328554e-05, -6.31330588e-03,  9.95627986e-01],
                 [ 1.00000000e+00,  6.32650000e-01, -3.06120000e-02, ...,
                   3.51474517e-07, -1.70067777e-08,  8.22905998e-10]])
```

5. Función sigmoide

```
In [144]: #Funcion sigmoide
          def h(z):
              return 1/(1 + np.exp(-z))
```

6. Función de coste

```
In [145]: [m,n]=X2.shape
```

7. Calculo de la función de coste según la fórmula. Para comprobar que es correcto probamos con theta todo a 0 y landa 1. Se obtiene 0.69314718

```
In [155]: def funCost(theta, X, Y, landa):
              return -(np.matmul(np.transpose(np.log(h(X@theta))), Y) +
                      (np.matmul(np.transpose(np.log(1-h(X@theta))), (1 - Y)))+
                       (landa/(2*m)) * (sum(theta**2)))/m
          funCost(np.zeros((n,1)),X2,Y2,1)
```

```
Out[155]: array([0.69314718])
```

8. Cálculo del gradiente

```
In [17]: Y2_aux = Y2[:, np.newaxis]
```

```
In [38]: def gradiente2(theta,X,Y,landa):
             return (((np.transpose(X))@(h(X@theta) - Y)) + ((landa/m)*theta))/m
         gradiente2(np.zeros((28,1)), mapFeature(), Y2_aux, 1)
```

```
Out[38]: array([[8.47457627e-03],
                [1.87880932e-02],
                [7.77711864e-05],
                [5.03446395e-02],
                [1.15013308e-02],
                [3.76648474e-02],
                [1.83559872e-02],
                [7.32393391e-03],
                [8.19244468e-03],
                [2.34764889e-02],
                [3.93486234e-02],
                [2.23923907e-03],
                [1.28600503e-02],
                [3.09593720e-03],
                [3.93028171e-02],
                [1.99707467e-02],
                [4.32983232e-03],
                [3.38643902e-03],
                [5.83822078e-03],
                [4.47629067e-03],
                [3.10079849e-02],
                [3.10312442e-02],
                [1.09740238e-03],
                [6.31570797e-03],
                [4.08503006e-04],
                [7.26504316e-03],
                [1.37646175e-03],
                [3.87936363e-02]])
```

9. Cálculo del valor óptimo de los parámetros

```
In [158]: def valorOptimo():
              output = opt.fmin_tnc(func = funCost, x0 = np.zeros((28,1)).flatten(), fprime = g
              theta = output[0]
              print(theta)

          valorOptimo()
```

```
[ 3.77377444  1.99417441  4.69597945 -5.44022689 -6.87638526 -5.89909717
  2.2590138   0.08940053  2.75128489 -2.7056456  -3.76442566  3.18093579
 -3.95743691 -1.91232391 -6.67407337 -1.85331642 -0.98793687  5.58587702
 -3.91736575 -4.84178202  3.19074231 -5.8564317   0.29735646 -0.87774435
  3.61191529 -5.03648702 -3.9206938   0.29653692]
```

9. Pintamos la frontera de regresión.

```
In [157]: graficaEjemplo2()
          poly = Pol.PolynomialFeatures(6)
          def plot_decisionboundary(X, Y, theta, poly):
              x1_min, x1_max = X[:, 0].min(), X[:, 0].max()
              x2_min, x2_max = X[:, 1].min(), X[:, 1].max()
              xx1, xx2 = np.meshgrid(np.linspace(x1_min, x1_max),
              np.linspace(x2_min, x2_max))
              h1 = h(poly.fit_transform(np.c_[xx1.ravel(),xx2.ravel()]).dot(theta))
              h1 = h1.reshape(xx1.shape)
              plt.contour(xx1, xx2, h1, [0.5], linewidths=1, colors='g')

          plot_decisionboundary(np.matrix(X2), Y2, theta, poly)
```

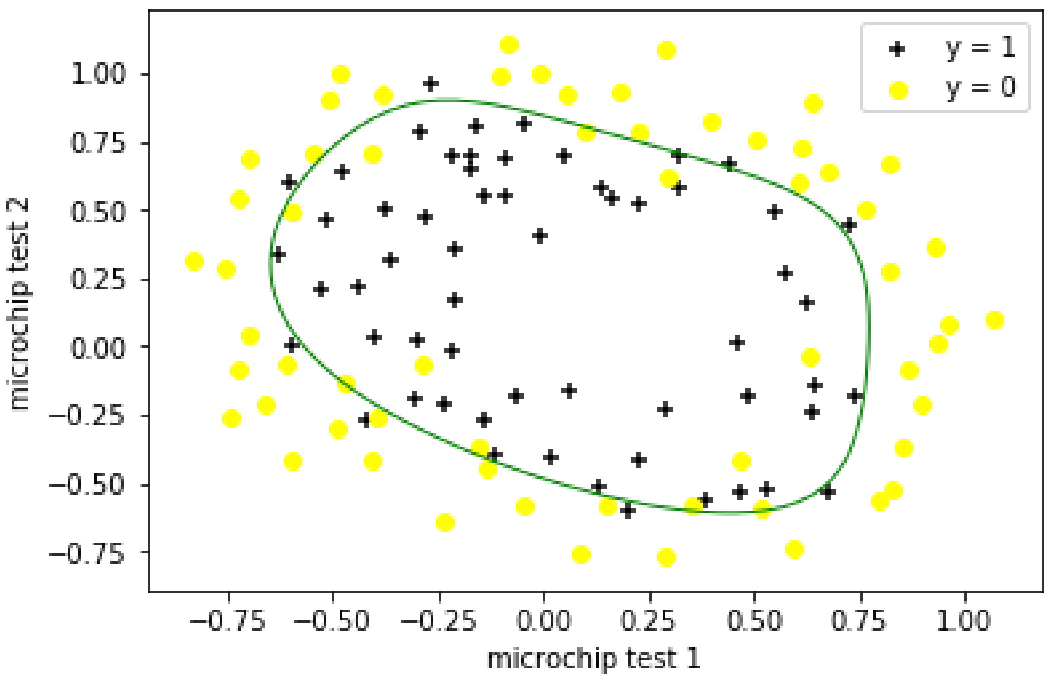

Alumnos: Carla Paola Peñarrieta Uribe y Hao Hao He